

CALCUL NUMERIC

Curs 1

Paul Irofti
Cristian Rusu
Andrei Pătrașcu

Departament Informatică
Universitatea din București

- **Valori singulare**
- Descompunerea Valorilor Singulare
- Rotație subspații
- Calcul DVS



Teoremă

Fie matricea $A \in \mathbb{R}^{m \times n}$ cu rangul $r \in [0, \min(m, n)]$, atunci există matricile ortonormale $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ astfel încât:

$$U^T A V = \Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}$$

unde

$$\Sigma_1 = \text{diag}(\sigma_1, \dots, \sigma_r),$$

cu

$$\sigma_1 \geq \dots \geq \sigma_r > 0.$$

Expresia $A = U \Sigma V^T$ se numește Descompunerea Valorilor Singulare a matricei A .

- σ_i se numesc valori singulare
- $U = [u_1 \ \dots \ u_m]$ se numesc vectori singolari la stânga
- $V = [v_1 \ \dots \ v_n]$ se numesc vectori singolari la dreapta

$$\begin{matrix} n \\ m \end{matrix} \boxed{A} = \begin{matrix} m \\ m \end{matrix} \boxed{U} \begin{matrix} n \\ m \end{matrix} \boxed{\Sigma} \begin{matrix} n \\ n \end{matrix} \boxed{V^T}$$


- Σ is unique and has the same form as A

- if $m < n$ then $\Sigma = \begin{bmatrix} \sigma_1 & 0 \cdots & 0 & 0 \cdots & 0 \\ 0 & \sigma_2 \cdots & 0 & 0 \cdots & 0 \\ \vdots & \vdots & \vdots & 0 \cdots & 0 \\ 0 & 0 \cdots & \sigma_m & 0 \cdots & 0 \end{bmatrix}$

- if $m > n$ then $\Sigma = \begin{bmatrix} \sigma_1 & 0 \cdots & 0 \\ 0 & \sigma_2 \cdots & 0 \\ \vdots & \vdots & \vdots \\ 0 & 0 \cdots & \sigma_m \\ 0 & \cdots & 0 \\ \vdots & \vdots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}$



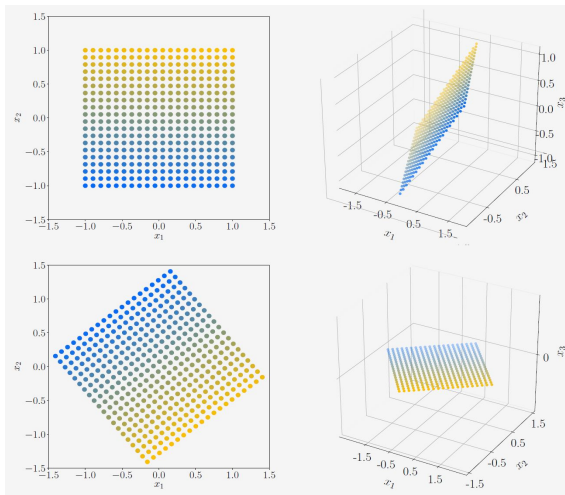
Valori și vectori singulari



$$A = \begin{bmatrix} 1 & -0.8 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = \underbrace{\begin{bmatrix} -0.79 & 0 & -0.62 \\ 0.38 & -0.78 & -0.49 \\ -0.48 & -0.62 & -0.62 \end{bmatrix}}_U \underbrace{\begin{bmatrix} 1.62 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} -0.78 & 0.62 \\ -0.62 & -0.78 \end{bmatrix}}_{V^T}$$



Valori și vectori singolari



Fie $A = U\Sigma V^T$, atunci:

- $Av_i = \sigma_i u_i$ și $A^T u_i = \sigma_i v_i$ pentru $i = 1 : n$
- σ_{\max} = valoarea singulară maximă a matricii A
- σ_{\min} = valoarea singulară minimă a matricii A
- $\sigma_{\min} \|x\|_2 \leq \|Ax\|_2 \leq \sigma_{\max} \|x\|_2$
- $A = \sum_{i=1}^r \sigma_i u_i v_i^T$
- Teoreme baze subspații și Eckart-Young



- Considerăm $A \in \mathbb{R}^{m \times n}$ matricea de date obținută dintr-un anume set de măsurători
- În general, dacă măsurătorile sunt repetate atunci o a doua matrice $B \in \mathbb{R}^{m \times n}$ este obținută

Problema Procrust Ortogonală: este posibil ca matricea B să fie obținută prin rotația lui A ?

$$\begin{aligned} \min_Q \quad & \|A - BQ\|_F \\ \text{s.l.} \quad & Q^T Q = I_n \end{aligned}$$

Soluția Q^* se calculează folosind descompunerea DVS!



$$\begin{aligned}\|A - BQ\|_F^2 &= \sum_{i=1}^n \|A_i - BQ_i\|_2^2 \\&= \sum_{i=1}^n \|A_i\|_2^2 + \|BQ_i\|_2^2 - 2\langle A_i, BQ_i \rangle \\&= \|A\|_2^2 + \|BQ\|_2^2 - 2 \sum_{i=1}^n [A^T BQ]_{ii} \\&= \|A\|_2^2 + \|B\|_2^2 - 2\text{Tr}(A^T BQ)\end{aligned}$$



Problema Procust originală se reduce la:

$$\begin{aligned} \max_Q \quad & \text{Tr}(QB^T A) \\ \text{s.l.} \quad & Q^T Q = I_n \end{aligned}$$

$$\text{DVS: } U^T(B^T A)V = \Sigma$$

$$\text{Notăm: } Z := VQU^T$$

$$\begin{aligned} \text{Tr}(QB^T A) &= \text{Tr}(QU^T \Sigma V) = \text{Tr}(VQU^T \Sigma) \\ &= \text{Tr}(Z \Sigma) = \sum_{i=1}^n Z_{ii} \sigma_i \leq \sum_{i=1}^n \sigma_i \end{aligned}$$

Soluția presupune ajustarea $Z = I_n$, adică $Q = UV^T$



Problema Procust originală se reduce la:

$$\begin{aligned} \max_Q \quad & \text{Tr}(QB^T A) \\ \text{s.l.} \quad & Q^T Q = I_n \end{aligned}$$

Algorithm 1: Procust

Data: $A, B \in \mathbb{R}^{m \times n}$

- 1 $C = B^T A$
 - 2 Calculează DVS: $U^T C V = \Sigma$
 - 3 $Q = UV^T$
-



Pentru orice $A \in \mathbb{R}^{m \times n}$, gramianul $A^T A \in \mathbb{R}^{n \times n}$ este o matrice simetrică pozitiv semidefinită, i.e.

$$A^T A = P \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} P^T \quad \text{unde } P^T P = I_n$$

Spectrul $\{\lambda_i\}_{1 \leq i \leq n}$ reprezintă valorile proprii ale matricii A .



Dacă presupunem disponibilă DVS a matricii A , atunci

$$\begin{aligned} A^T A &= (U \Sigma V^T)^T (U \Sigma V^T) = V \Sigma \underbrace{U^T U}_{I_n} \Sigma V^T \\ &= V \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_n^2 \end{bmatrix} V^T \end{aligned}$$

Se identifică:

$$V^T = P^T$$

$$\sigma_i^2 = \lambda_i$$

Vectorii proprii ai lui $A^T A$ compun vectorii singulari la dreapta a lui A !



Aplicăm o procedură similară pentru vectorii singulari la stânga:

$$\begin{aligned} AA^T &= (U\Sigma V^T)(U\Sigma V^T)^T = U\Sigma \underbrace{V^T V}_{I_n} \Sigma U^T \\ &= U \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_m^2 \end{bmatrix} U^T \end{aligned}$$

Matricea AA^T este diagonalizabilă, deci este posibil calculul vectorilor proprii
 $AA^T = QSQ^T$

Se identifică:

$$U = Q$$

Vectorii proprii ai lui AA^T compun vectorii singulari la stânga ai lui A !

- Step 1: Formează $C = A^T A$
- Step 2: Aplică algoritmul QR simetric pentru calculul V astfel:
 $V^T C V = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$
- Step 3: Calculează $u_i = \frac{1}{\sigma_i} A v_i$ pentru $i = 1 : n$
- Step 3': Calculează folosind fact. QR $AV = \underbrace{U}_Q \underbrace{\Sigma}_R$



- Step 1: Formează $C = A^T A$
- Step 2: Aplică algoritmul QR simetric pentru calculul V astfel:
 $V^T C V = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$
- Step 3: Calculează $u_i = \frac{1}{\sigma_i^2} A v_i$ pentru $i = 1 : n$
- Step 3': Calculează folosind fact. QR $AV = \underbrace{U}_Q \underbrace{\Sigma}_R$

În practică formarea $A^T A$ sau AA^T este costisitoare!



- Step 1: Formează $C = A^T A$
- Step 2: Aplică algoritmul QR simetric pentru calculul V astfel:
 $V^T C V = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$
- Step 3: Calculează $u_i = \frac{1}{\sigma_i^2} A v_i$ pentru $i = 1 : n$
- Step 3': Calculează folosind fact. QR $AV = \underbrace{U}_Q \underbrace{\Sigma}_R$

În practică formarea $A^T A$ sau AA^T este costisitoare! Exemplu în carte!



- Van Loan, Charles F., and G. Golub. "Matrix computations (Johns Hopkins studies in mathematical sciences)." (1996).

